Universidade do Porto
FEUP Faculdade de Engenharia

Conceção e análise de algoritmos

Plagiarism Checker

Fábio Filipe Jesus Silva - ei11107

Fernando Manuel Rocha Magalhães - ei07046

José Pedro Lobo Marinho Trocado Moreira - ei12002

Porto, 28 de maio de 2013

Resumo

Este trabalho contextualiza-se num sistema de deteção de plágio de ficheiros de texto.
Tal deteção é feita através do conceito de **subsequência comum mais comprida**, com recurso a programação dinâmica.

Este sistema compara um ficheiro de texto com uma base de dados (neste caso um diretório com vários ficheiros de texto) e calcula o grau de similaridade entre ambos.

Sendo assim, os dados de entrada são, portanto, os caminhos para a base de dados e para o ficheiro de texto. Tais caminhos podem ser inseridos das seguintes maneiras:

- Manualmente (pedido pelo programa em tempo de execução)
- "Arrastando" a pasta e o ficheiro para o executável (*Windows*)
- Como parâmetros da linha de comandos (*Windows* e *GNU/Linux*)

Como se dá a entender, o programa é passível de ser compilado tanto em *Windows* como em *GNU/Linux*.

Embora cada uma destas plataformas use funções distintas ao nível dos diretórios, o código-fonte está devidamente preparado para compilação em ambas.

Em termos de resultado final, espera-se que o programa devolva, para cada um dos ficheiros na base de dados:

- *Strings* similares às do ficheiro novo (isto é, com um número maior ou igual de carateres definido)
- Grau de similaridade percentual em relação ao ficheiro novo

Universidade do Porto
FEUP Faculdade de Engenharia

Índice

Principais algoritmos

O "método" usado para este trabalho foi o **LCS** (*Longest Common Sequence*), com recurso a programação dinâmica.

Em termos de complexidade teórica, carateriza-se por ser linear no comprimento das *strings* a comparar (**O** (n x m)), sendo *n* e *m* os comprimentos das *strings*.

Na prática, este comportamento foi verificado, como mostra a tabela abaixo.

m	n	t1	t2	t3	t médio	α
3305	726	0.033215	0.0332181	0.0350442	0.033825767	0.000047
3305	2135	0.0983369	0.0990908	0.0994	0.189894256	0.000046
3305	3978	0.184175	0.184447	0.183184	0.183935333	0.000046

m	n	t1	t2	t3	t médio	α
5833	7835	0.446651	0.427481	0.426716	0.433616	0.000074
2652	7835	0.193787	0.193083	0.19376	0.193543333	0.000073
518	7835	0.0383321	0.0388155	0.0383933	0.0385133	0.000074

Nas tabelas acima, as variáveis *t1*, *t2* e *t3* representam três ensaios feitos ao tempo de execução em seis ensaios diferentes, onde se variou ora *m*, ora *n*.

α representa a proporcionalidade entre o comprimento da *string* e o tempo levado a executar o algoritmo.

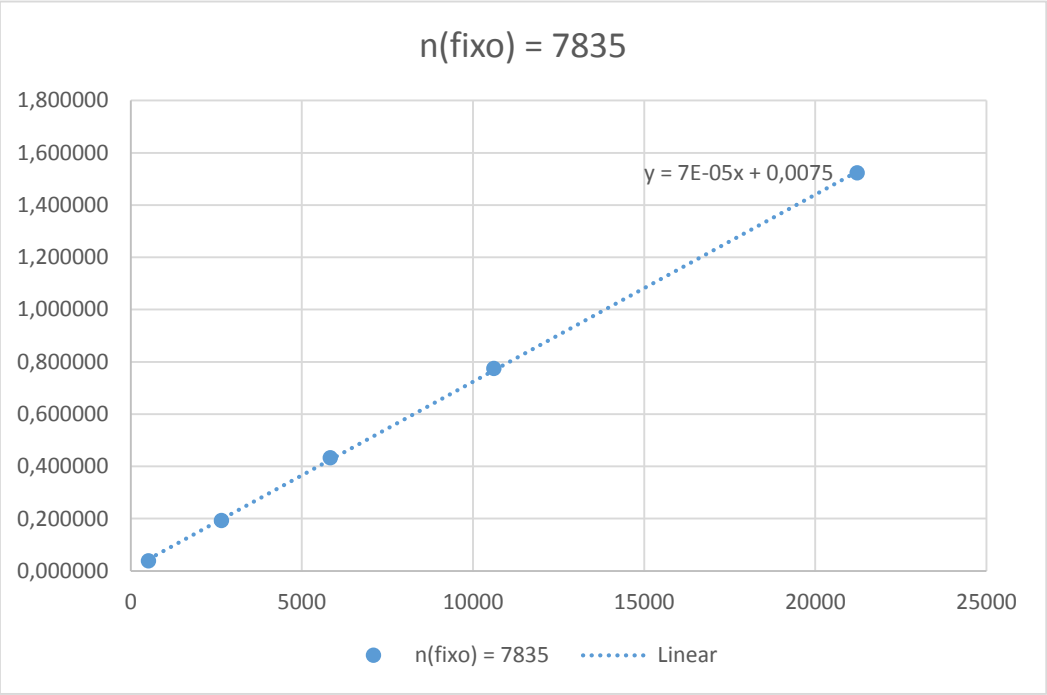

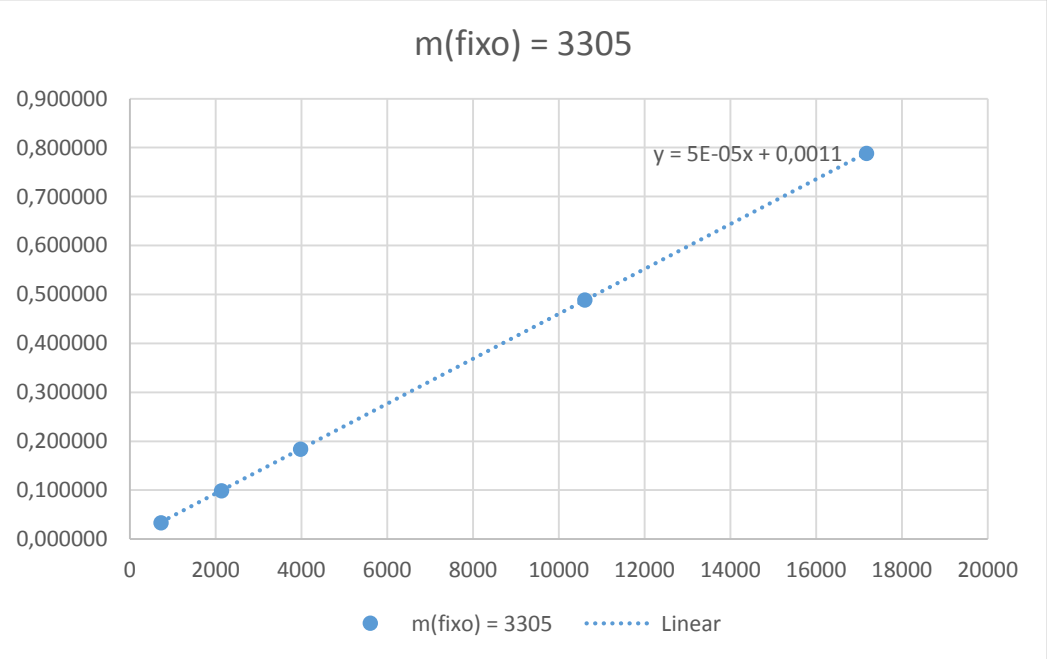

Através destes gráficos gerados com os valores das tabelas, verifica-se que há pois uma dependência linear entre os tamanhos das *strings* e os tempos de execução, que é demonstrada também pelos valores semelhantes de **α.**

Principais dificuldades e esforço individual

Em geral, este segundo projeto foi mais acessível que o primeiro.

No entanto, o mais difícil foi sem dúvida compatibilizar o código tanto para *Windows* como para *GNU/Linux*. Isto deve-se ao fato de as funções relativas a diretórios variarem em ambas as plataformas.

A solução que implementámos foi a compilação condicional, com o auxílio de diretivas de pré-processamento.

Quanto ao trabalho desempenhado por cada membro do grupo, esse foi equitativo.

Bibliografia

http://en.wikipedia.org/wiki/Diff - Página *wiki* sobre o comando ***diff*** (*GNU*/*Linux*), que se assemelha ao nosso projeto

http://en.wikipedia.org/wiki/Longest_common_subsequence_problem - Página *wiki* sobre o método LCS (*Longest Common Sequence*), no qual se baseia o comando acima e consequentemente também o nosso projeto.

http://en.wikipedia.org/wiki/C_preprocessor - Página relacionada com o pré-processador em C/C++, que nos ajudou a criar código multiplataforma.

Conclusão

Em suma, podemos afirmar que este sistema de deteção de plágio comporta-se de maneira bastante satisfatória, pois apresenta taxas de similaridade muito reais.

Apesar das dificuldades supra citadas, foi um trabalho que nos agradou realizar, pois permitiu-nos apreender conceitos relacionados com algoritmos direcionados a *strings*, que no fundo era o real objetivo de todo o projeto.